# Inhaltsverzeichnis

**1 Einleitung** **2**

**2 Theoretische Grundlagen** **3**

**3 Methodik und Systementwurf** **4**

**4 Versuchsaufbau und Evaluationsprotokoll** **6**

**5 Ergebnisse** **7**

**6 Sensitivitätsanalyse der Patientenparameter** **11**

**7 Diskussion** **12**

**8 Fazit und Ausblick** **13**

**Literaturverzeichnis** **14**

# 1 Einleitung

## 1.1 Motivation

Bei Typ-1-Diabetes zerstört das Immunsystem die insulinproduzierenden Zellen der Bauchspeicheldrüse. Die Betroffenen müssen die Regelung des Blutzuckers, die der Körper sonst selbst übernimmt, lebenslang von außen nachbilden. Zu wenig Insulin führt über Jahre zu Folgeschäden an Augen, Nieren und Nerven, zu viel Insulin binnen Minuten zu Krampfanfall und Bewusstlosigkeit. Die Regelaufgabe ist also nicht symmetrisch, und sie ist verzögert: gespritztes Insulin wirkt erst nach Minuten bis Stunden, eine Mahlzeit hebt den Blutzucker schneller an, als jede Gegenmaßnahme greifen kann.

Moderne Systeme messen den Blutzucker kontinuierlich (Continuous Glucose Monitoring, CGM) und steuern eine Insulinpumpe. Damit wird die Regelung zu einem Anwendungsfall für maschinelles Lernen. Genau hier entsteht jedoch eine Lücke, die in Simulationsstudien leicht übersehen wird: ein Simulator kennt den wahren Zustand des Patienten, ein reales Gerät kennt ihn nicht.

## 1.2 Problemstellung

Ein Simulationsmodell wie das UVA/Padova-Modell (Dalla Man u. a. 2014) hält zu jedem Zeitpunkt den vollständigen physiologischen Zustand vor: Glukose im Magen, im Darm, im Plasma und im Gewebe, Insulin in mehreren Kompartimenten. Ein Algorithmus, der in dieser Umgebung trainiert wird, kann auf all das zugreifen. Ein Gerät am Patienten sieht davon nichts. Es sieht einen einzigen Messwert, und dieser Messwert stammt nicht einmal aus dem Blut, sondern aus dem Unterhautfettgewebe. Er ist verrauscht und er hinkt hinterher.

Die daraus folgende Frage ist keine akademische Spitzfindigkeit, sondern entscheidet darüber, ob ein in Simulation gemessenes Ergebnis etwas über die Wirklichkeit aussagt.

## 1.3 Zielsetzung

Ziel dieser Arbeit ist, den Effekt dieser Informationslücke sauber zu messen, statt ihn zu umgehen. Dazu werden zwei Agenten unter vollständig identischen Bedingungen trainiert und ausgewertet. Gleich sind die Dynamik, die Belohnungsfunktion, die Netzarchitektur, die Hyperparameter, die Startzustände und die Mahlzeitenszenarien. Verschieden ist ausschließlich der Beobachtungsraum:

- Der **privilegierte** Agent liest den vollständigen 13-dimensionalen Modellzustand, den wahren Plasmaglukosewert und angekündigte Mahlzeiten. Diese Information existiert nur im Simulator.
- Der **CGM-Agent** liest ausschließlich den Verlauf des Sensorsignals, seine eigene Insulinhistorie und die Tageszeit. Das ist genau das, was ein einsetzbares System sieht.

Damit die Größe dieses Effekts einzuordnen ist, wird eine zweite Achse gekreuzt: ein *generalistischer* Regler für eine ganze Kohorte gegenüber *personalisierten* Reglern, je einer pro Patient. Die

Frage lautet dann nicht nur, wie groß die Informationslücke ist, sondern auch, wie sie sich zu einem vertrauten Hebel verhält: ist es wichtiger, wen man regelt, oder was man sieht.

Als Bezugspunkt dient nicht ein willkürlicher Vergleichswert, sondern die übliche klinische Praxis: eine Basal-Bolus-Therapie mit Kohlenhydrat- und Korrekturfaktor. Bewertet wird nach den internationalen Konsenszielen zur Time in Range (Battelino u. a. 2019) auf zehn Held-out-Patienten, die der generalistische Regler nie trainiert.

### 1.4 Forschungsfragen

**F1** Wie groß ist die Wahrnehmungslücke zwischen privilegierter und beobachtbarer Information, gemessen als Regelgüte unter sonst identischen Bedingungen?

**F2** Lässt sich ein brauchbarer Regler überhaupt allein durch Reinforcement Learning finden, oder ist ein Warmstart durch Imitation der klinischen Therapie notwendig?

**F3** Welche Entwurfsentscheidungen bei Aktionsraum, Exploration und Belohnung entscheiden über Erfolg oder Misserfolg, und lassen sie sich vorab begründen statt nachträglich anpassen?

**F4** Welche physiologischen Parameter des Modells bestimmen, wie gut sich ein Patient überhaupt regeln lässt?

**F5** Wie verhält sich die Informationslücke zum Gewinn durch Personalisierung?

## 2 Theoretische Grundlagen

### 2.1 Das UVA/Padova-Modell

Das in dieser Arbeit verwendete Simulationsmodell beschreibt die Glukose- und Insulinkinetik eines Typ-1-Diabetikers durch dreizehn gekoppelte gewöhnliche Differentialgleichungen (Dalla Man u. a. 2014). Es gehört damit zur selben Klasse wie das Räuber-Beute-Modell oder das Noble-Modell der Herzerregung, ist aber deutlich größer. Gelöst wird es numerisch mit einem Runge-Kutta-Verfahren (`dopri5`) in Schritten von einer Minute (Virtanen u. a. 2020).

Die Zustände umfassen Glukose in Magen ($x_0, x_1$) und Darm ($x_2$), im Plasma ($x_3$) und im Gewebe ($x_4$), die Insulinkinetik und Insulinwirkung ($x_5$ bis $x_9$), das subkutane Insulin ($x_{10}, x_{11}$) sowie die subkutane Glukose ($x_{12}$). Zwei davon tragen die gesamte Fragestellung dieser Arbeit: $x_3$ ist der wahre Blutzucker, $x_{12}$ das, was der Sensor misst.

Die Kopplung zwischen beiden lautet

$$\frac{\mathrm{d}x_{12}}{\mathrm{d}t} = k_{sc}\left(x_3 - x_{12}\right), \tag{1}$$

also ein Verzögerungsglied erster Ordnung. Der Sensor misst somit grundsätzlich eine verzögerte Größe, unabhängig von seiner Genauigkeit.

Auf diesen Wert addiert das Sensormodell zusätzlich korreliertes Rauschen: ein AR(1)-Prozess wird alle 15 Minuten erzeugt, kubisch auf die Abtastzeit von drei Minuten interpoliert und durch eine Johnson-SU-Transformation geschickt. Das Rauschen ist damit nicht weiß und lässt sich nicht durch einfache Mittelung entfernen.

### 2.2 Reinforcement Learning und PPO

Reinforcement Learning beschreibt das Lernen von Verhalten aus einem Belohnungssignal (Sutton und Barto 2018). Formal liegt ein Markow-Entscheidungsprozess vor. Der Agent wählt in Zustand $s_t$ nach seiner Politik $\pi_\theta$ eine Aktion, erhält die Belohnung $r_t$ und geht nach $s_{t+1}$ über. Gesucht ist die Politik, die den erwarteten diskontierten Ertrag $\mathbb{E}[\sum_t \gamma^t r_t]$ maximiert.

Verwendet wird Proximal Policy Optimization (Schulman u. a. 2017) in der Implementierung von Stable-Baselines3 (Raffin u. a. 2021). PPO begrenzt die Änderung der Politik je Aktualisierungsschritt über ein abgeschnittenes Wahrscheinlichkeitsverhältnis und bleibt dadurch auch bei langen Episoden stabil. Bei kontinuierlichen Aktionen gibt die Politik Mittelwert und Standardabweichung einer Normalverteilung aus; die Standardabweichung steuert die Exploration und entscheidet hier über Erfolg und Misserfolg (Abschnitt 3).

### 2.3 Privilegierte Information und Imitationslernen

Wird ein Lehrer mit Zugriff auf nicht einsetzbare Information trainiert und anschließend ein Schüler darauf trainiert, dessen Verhalten aus einsetzbaren Beobachtungen nachzubilden, spricht man von Lernen mit privilegierter Information; Chen u. a. (2019) prägten dafür den Begriff *Learning by Cheating*. Bleibt der Schüler hinter dem Lehrer zurück, liegt das nicht notwendig an zu wenig Kapazität oder Rechenzeit, sondern kann daran liegen, dass die nötige Information in seiner Beobachtung schlicht nicht enthalten ist. Genau diese Unterscheidung ist der Kern der vorliegenden Arbeit.

Reines Nachahmen leidet unter Verteilungsverschiebung (Ross u. a. 2011); hier dient die Imitation nur als Warmstart, die eigentliche Optimierung übernimmt anschließend PPO.

### 2.4 Klinische Bewertungsmaßstäbe

Bewertet wird nach dem internationalen Konsens zur Time in Range (Battelino u. a. 2019). Tabelle 1 nennt die Schwellen und Zielwerte.

**Tabelle 1:** Konsensziele für Typ-1-Diabetes (Battelino u. a. 2019).

| Kennzahl | Bereich | Zielwert |
|---|---|---|
| Time in Range (TIR) | 70 mg/dL bis 180 mg/dL | $> 70\,\%$ |
| Time below Range gesamt | $< 70$ mg/dL | $< 4\,\%$ |
| Time below Range Level 2 | $< 54$ mg/dL | $< 1\,\%$ |
| Time above Range gesamt | $> 180$ mg/dL | $< 25\,\%$ |
| Time above Range Level 2 | $> 250$ mg/dL | $< 5\,\%$ |
| Variationskoeffizient | — | $< 36\,\%$ |

Bemerkenswert und für die Belohnungsgestaltung entscheidend ist die **Asymmetrie**: oberhalb des Zielbereichs werden bis zu 25 % der Zeit toleriert, unterhalb nur 4 %. Unterzuckerung wirkt akut, Überzuckerung chronisch.

Ergänzend dient der Risikoindex nach Kovatchev u. a. (1997) als Belohnungsgrundlage. Er bildet den Blutzucker über $f(\mathrm{BG}) = 1{,}509(\ln(\mathrm{BG})^{1{,}084} - 5{,}381)$ auf eine symmetrisierte Skala ab, quadriert sie zu $\mathrm{RI} = 10 f^2$ und trennt den Anteil unterhalb (LBGI) vom Anteil oberhalb (HBGI). Abschnitt 5 zeigt allerdings, dass er als alleiniges Belohnungssignal die klinische Rangfolge verfehlt.

## 3 Methodik und Systementwurf

Dieser Abschnitt begründet die Entwurfsentscheidungen. Jede wird mit der verworfenen Alternative dargestellt, weil gerade die verworfenen Varianten die Eigenschaften des Problems sichtbar machen.

### 3.1 Eigene Umgebung statt der mitgelieferten

Die Simulationsbibliothek `simglucose` (Xie 2018) bringt eine fertige Lernumgebung mit. Sie wird hier nicht verwendet. Zwei Gründe sind inhaltlich, einer ist technisch.

1. **Die Beobachtung ist ein einzelner Messwert ohne Verlauf.** Ohne Historie kann ein Agent keinen Trend erkennen. Bei einer Sensorverzögerung von zwölf Minuten ist der Trend jedoch die eigentliche Information.

2. **Der Aktionsraum ist falsch skaliert.** Er ist als $\mathrm{Box}(0, u_{max})$ mit $u_{max} = 30$ U/min definiert, während die physiologische Basalrate des Patienten `adult#001` bei 0,021.12 U/min liegt. Das Verhältnis beträgt 1.420. Ein gleichverteilt ziehender Agent gäbe in nahezu jedem Schritt eine tödliche Dosis.

3. Technisch verlangt das Modul zudem das seit 2017 nicht mehr gepflegte Paket `gym`, das unter Python 3.10 nicht mehr baut.

Stattdessen setzt eine eigene Umgebung direkt auf dem Löser auf. Sie kapselt Beobachtung, Aktion und Belohnung und lässt die Modellphysik unberührt.

### 3.2 Aktionsraum, aus der klinischen Referenz hergeleitet

Statt den Aktionsbereich zu schätzen, wurde gemessen, welche Insulinraten die klinische Standardtherapie tatsächlich anfordert (Tabelle 2).

**Tabelle 2:** Angeforderte Insulinraten des Basal-Bolus-Reglers über je einen simulierten Tag, in U/min.

| Patient | Basalrate | 99. Perzentil | Maximum | Maximum/Basalrate |
|---|---|---|---|---|
| adult#001 | 0,02112 | 0,0211 | 2,6211 | 124,1 |
| adolescent#001 | 0,01394 | 0,0139 | 2,1806 | 156,5 |
| child#001 | 0,00658 | 0,0066 | 1,0466 | 159,1 |

Die Verteilung ist extrem schief: in 99 % der Schritte exakt die Basalrate, im Maximum das 124- bis 159-fache. Ein linearer Aktionsraum verschwendet seine gesamte Auflösung dort, wo praktisch keine Entscheidungen liegen. Gewählt wird deshalb ein logarithmischer Aktionsraum,

$$u = u_{basal} \cdot M^{\,a}, \qquad a \in [-1, 1], \qquad M = 160, \tag{2}$$

wobei $u_{basal}$ die stationäre Basalrate des jeweiligen Patienten ist. Die Aktion $a = 0$ liefert exakt diese Basalrate, $a = 1$ das 160-fache, $a = -1$ praktisch null. Der Aktionsraum ist damit patientennormiert und ohne Umskalierung auf jede Kohorte übertragbar; der Faktor 160 folgt unmittelbar aus Tabelle 2.

## 3.3 Die beiden Beobachtungsräume

**Tabelle 3:** Beobachtungsräume. Der einzige Unterschied im gesamten Versuch.

| Modus | Dim. | Inhalt |
|---|---|---|
| `privileged` | 31 | 13 normierte Modellzustände, wahre Plasmaglukose, CGM-Wert, aktuell aufgenommene Kohlenhydrate, **angekündigte Mahlzeit** im 30-Minuten-Fenster, Insulinhistorie (12 Schritte), Tageszeit (Sinus, Kosinus) |
| `cgm` | 26 | CGM-Verlauf (12 Schritte, 36 Minuten), Insulinhistorie (12 Schritte), Tageszeit. Keine Ankündigung, kein wahrer Wert, kein Modellzustand |

## 3.4 Belohnungsfunktion

**Abbruchstrafe.** Der Simulator beendet die Episode, wenn der Blutzucker den überlebbaren Bereich verlässt. Eine *flache* Strafe wäre hier ein Konstruktionsfehler. Rechnet man die Rückgaben über eine Episode von 480 Schritten durch, kostet anhaltende Überzuckerung rund $-619$, ein Abbruch nach 100 Schritten mit flacher Strafe $-100$ dagegen nur rund $-300$. Der Agent hätte einen Anreiz, die Episode absichtlich zu beenden. Stattdessen wird der Abbruch mit dem *maximalen* Risiko für die verbleibende Episodendauer belastet:

$$r_{term} = -w_{risk} \cdot \mathrm{RI}_{max} \cdot (T - t). \tag{3}$$

Sterben ist damit exakt so teuer wie die schlechtestmögliche Regelung bis zum Episodenende, nie billiger. Der Fehler wurde rein rechnerisch gefunden, vor dem ersten Trainingslauf.

**Belohnung v1 und ihr Scheitern.** Version v1 verwendete allein den negativen Risikoindex, $r = -0{,}1 \cdot \mathrm{RI(BG)}$. Das Ergebnis ist in Abschnitt 5 dokumentiert: der Agent treibt den Blutzucker systematisch nach unten. Die Ursache liegt im Index selbst, der milde Unterzuckerung *günstiger* bewertet als mäßige Überzuckerung.

**Belohnung v2.** Ergänzt wird eine explizite, an den Konsensgrenzen ausgerichtete asymmetrische Strafe:

$$r_{hypo} = \begin{cases} -w_{hypo}\dfrac{70 - \mathrm{BG}}{70} - w_{sev}, & \mathrm{BG} < 54, \\ -w_{hypo}\dfrac{70 - \mathrm{BG}}{70}, & 54 \le \mathrm{BG} < 70, \\ 0, & \text{sonst}, \end{cases} \tag{4}$$

mit $w_{hypo} = 10$ und $w_{sev} = 2$. Im Zielbereich und im gesamten hyperglykämen Ast bleibt v2 identisch zu v1; nur der hypoglykäme Ast wird verschärft.

### 3.5 Exploration: warum sie hier der entscheidende Parameter ist

Ein Mahlzeitenbolus entspricht nach Gleichung (2) einer Aktion von etwa 0,76 bis 0,95. Wie oft eine Politik so etwas überhaupt zieht, hängt allein an der Explorationsbreite $\sigma$ (Tabelle 4).

**Tabelle 4:** Erwartete Zahl bolusgroßer Aktionen je Episode (480 Schritte).

| $\log \sigma$ | $\sigma$ | Abstand zu $a = 0{,}897$ | Treffer je Episode |
|---|---|---|---|
| $-1{,}5$ | 0,223 | $4{,}02\,\sigma$ | **0,014** |
| $-1{,}0$ | 0,368 | $2{,}44\,\sigma$ | 3,54 |
| $-0{,}8$ | 0,449 | $2{,}00\,\sigma$ | 11,02 |
| 0,0 | 1,000 | $0{,}90\,\sigma$ | 88,73 |

Daraus folgt ein Zielkonflikt, der sich über diesen einen Parameter nicht lösen lässt. Bei $\log \sigma = -1{,}5$ zieht der Agent in rund siebzig Episoden einmal eine bolusgroße Dosis und kann das Bolussieren nie entdecken. Bei $\log \sigma = -1{,}0$ entdeckt er es, tötet den Patienten aber in 97 % der Episoden. Beide Fälle sind gemessen (Abschnitt 5).

### 3.6 Warmstart durch Imitation

Der Ausweg besteht nicht in weiterer Feinjustierung der Exploration, sondern in einem brauchbaren Startpunkt. Die Politik wird zunächst darauf trainiert, den Basal-Bolus-Regler nachzubilden (Behavioral Cloning, 150 Lehrer-Episoden, 72.000 Beobachtung-Aktion-Paare), und erst danach mit PPO weiter optimiert. Beim Fortsetzen wird die Explorationsbreite auf $\log \sigma = -2{,}5$ gesetzt, denn der Agent muss das Bolussieren nun nicht mehr *entdecken*, sondern nur noch *verfeinern*.

Dieser Aufbau ist zugleich die inhaltliche Klammer der Arbeit. Der Lehrer sieht die angekündigte Mahlzeit. Der privilegierte Schüler sieht sie ebenfalls, der CGM-Schüler nicht. Wie gut jeder den Lehrer trotzdem nachbildet, ist ein direktes Maß für die Wahrnehmungslücke.

### 3.7 Laufzeit

Zwei Engpässe fand das Profiling, beide ohne Änderung der Modellphysik behoben. Die rechte Seite des Differentialgleichungssystems liest rund dreißig Parameter aus einer `pandas`-Struktur, bei etwa 23 Auswertungen je Umgebungsschritt rund 70 % der Laufzeit; ein einmaliges Kopieren in echte Attribute beschleunigt um den Faktor **5,42** bei *bitidentischem* Ergebnis. Jeder Episodenreset lud zudem dreimal die Parameterdateien und baute das Szenario doppelt auf, was die Resetzeit von 16,4 ms auf 3,99 ms drücken ließ. Das zählt, weil die vektorisierte Umgebung synchron arbeitet: ein resettender Prozess hält alle anderen auf.

## 4 Versuchsaufbau und Evaluationsprotokoll

### 4.1 Kohorte und Versuchsplan

Der Simulator liefert dreißig virtuelle Patienten, je zehn Jugendliche, Erwachsene und Kinder (Dalla Man u. a. 2014). Sie werden geschichtet aufgeteilt in 20 Trainingspatienten (7 Jugendliche, 7 Erwachsene, 6 Kinder) und 10 Held-out-Patienten (3, 3, 4). Die Trennung erfolgt auf Ebene der *Patienten*, nicht nur der Szenarien: die zehn Held-out-Physiologien sieht der generalistische Regler nie.

Daraus ergibt sich ein Versuchsplan mit zwei Achsen (Tabelle 5). Die erste ist die eigentliche Fragestellung, die zweite dient dazu, deren Größe einzuordnen.

**Tabelle 5:** Versuchsplan. Alle vier Zellen werden auf denselben zehn Held-out-Patienten und denselben Episoden-Seeds ausgewertet.

| | generalistisch | personalisiert |
|---|---|---|
| privilegiert | ein Regler, 20 Patienten | ein Regler je Patient |
| nur CGM | ein Regler, 20 Patienten | ein Regler je Patient |

Dass ein *einziger* Regler eine ganze Kohorte bedienen kann, ist eine Folge des Aktionsraums aus Gleichung (2): die Aktion ist auf die patienteneigene Basalrate normiert, dieselbe Aktion bedeutet für ein Kind und einen Erwachsenen also dieselbe *relative* Dosis. Die Basalraten der Kohorte reichen von 0,004.81 U/min bis 0,028.74 U/min, unterscheiden sich also um den Faktor 6,0. Ohne diese Normierung wäre ein gemeinsamer Aktionsraum nicht sinnvoll definierbar.

### 4.2 Szenarien und Trennung von Training und Bewertung

Eine Episode entspricht einem simulierten Tag, also 480 Schritten zu je drei Minuten. Ein Episoden-Seed steuert gemeinsam den Mahlzeitenplan, das Sensorrauschen, den Startblutzucker und die Startuhrzeit, sodass jede Episode exakt reproduzierbar ist.

Die Seed-Bereiche beider Phasen sind **disjunkt**: das Training zieht aus $[0, 10^5)$, die Bewertung beginnt bei $10^5$. Kein Bewertungsszenario wird je trainiert. Zusammen mit der Patiententrennung entstehen zwei Stufen der Verallgemeinerung, die der Ergebnisteil trennt: neue *Szenarien* bei bekannten Patienten, und neue *Patienten*. Der Mahlzeitenplan wird pro Szenario neu gezogen, mit Frühstück, Mittag- und Abendessen bei Wahrscheinlichkeit 0,95 und drei Zwischenmahlzeiten bei 0,3.

### 4.3 Referenzregler

Zwei Referenzen laufen über *dasselbe* Episodenprotokoll und dieselben Seeds wie der lernende Agent:

- **Konstante Basalrate.** Keine Regelung, nur die stationäre Basalrate. Die untere Schranke.
- **Basal-Bolus-Therapie.** Die übliche klinische Praxis mit Kohlenhydratfaktor und Korrekturfaktor. Dieser Regler bekommt die Mahlzeit angekündigt, wie ein Patient am Bolusrechner.

### 4.4 Hyperparameter

Beide Agenten sind bis auf den Beobachtungsraum identisch konfiguriert: PPO aus Stable-Baselines3 2.9.0, MLP $64\times64$ getrennt für Politik und Kritiker, Lernrate $3\times10^{-4}$, Rollout aus 24 Umgebungen zu je 256 Schritten, Minibatch 256 über 5 Epochen, $\gamma = 0{,}99$, $\lambda_{GAE} = 0{,}95$, Clipping 0,2, Belohnung v2. Die Explorationsbreite beträgt $\log\sigma = -1{,}0$ im Warmstart und $\log\sigma = -2{,}5$ in der Feinabstimmung, diese über 600.000 Schritte generalistisch und 250.000 je personalisiertem Regler. Jeder Lauf legt diese Werte als `config.json` ab.

### 4.5 Protokollierung und Rechenumgebung

Jede einzelne Episode wird im Training wie in der Bewertung als eigene Zeile mit vollständigem Metriksatz geschrieben, jeder Lauf zusätzlich mit einer `config.json` aus Hyperparametern, Belohnungsgewichten und Paketversionen. Alle Tabellen und Abbildungen dieser Arbeit entstehen daraus ohne erneuten Lauf, und die Ergebnisabschnitte können Einzeldurchläufe statt bloßer Mittelwerte zeigen.

Gerechnet wurde auf einem AMD Ryzen 7 5700X (8 Kerne) mit 21 GB Arbeitsspeicher. Die Politik läuft auf der CPU schneller als auf der GPU, weil bei einem $64 \times 64$-Netz der Transferaufwand je Minibatch dominiert. Begrenzend ist die Simulation, nicht das Lernen: nach den Optimierungen aus Abschnitt 3 erreicht die vektorisierte Umgebung rund 3.600 Umgebungsschritte pro Sekunde bei 24 Prozessen.

## 5 Ergebnisse

Alle Zahlen stammen aus deterministischer Auswertung. Referenzregler und Agenten durchlaufen dasselbe Episodenprotokoll. Die Hauptergebnisse (Abschnitt 5.5) beruhen auf den zehn Held-out-Patienten mit je 20 Episoden, also 200 Episoden je Versuchszelle, und auf **zwei unabhängigen Trainingsdurchläufen** je Zelle.

### 5.1 Die Beobachtbarkeitslücke ist physikalisch, nicht konstruiert

Vor jedem Lernergebnis steht die Frage, wie groß der Unterschied zwischen wahrem und messbarem Zustand überhaupt ist. Gemessen wurde über 20 Episoden bei konstanter Basalrate, nicht über eine einzelne: das Sensorrauschen ist eine Zufallsgröße, deren Standardabweichung zwischen einzelnen Tagen von 6,85 bis 16,37 schwankt.

Die subkutane Glukose hinkt der Plasmaglukose um 12 min hinterher (vier Schritte, Maximum der Kreuzkorrelation), und zwar in 20 von 20 Episoden. Das Sensorrauschen hat eine Standardabweichung von $11{,}04 \pm 2{,}32$ mg/dL, der mittlere Betragsfehler des Sensorwerts gegenüber der Plasmaglukose beträgt $10{,}01 \pm 1{,}64$ mg/dL. Die Verzögerung folgt unmittelbar aus Gleichung (1) und ist damit eine Eigenschaft des Modells, keine Zutat dieser Arbeit.

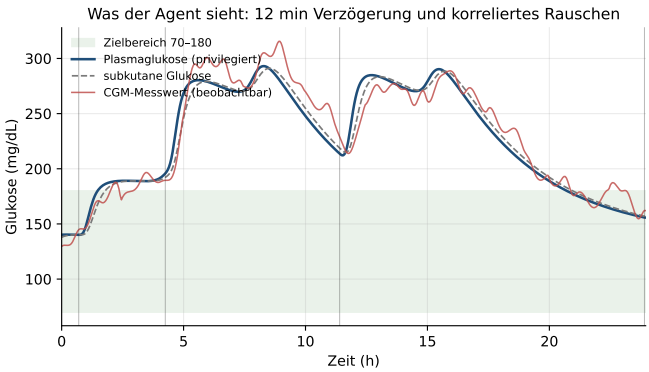



**Abbildung 1:** Plasmaglukose, subkutane Glukose und Sensorsignal über einen simulierten Tag. Nur die verrauschte Kurve steht einem einsetzbaren Regler zur Verfügung. Senkrechte Linien markieren Mahlzeiten.

## 5.2 Zwei verworfene Entwürfe

**Explorationsbreite.** Beide Enden des in Tabelle 4 hergeleiteten Zielkonflikts wurden vollständig trainiert und scheitern. Bei $\log \sigma = -1{,}0$ entdeckt der Agent das Bolussieren und tötet den Patienten in 97 % der Episoden. Bei $\log \sigma = -1{,}5$ überlebt jede Episode, doch über beide Auswertungszeitpunkte zieht die deterministische Politik in 20 Episoden *keine einzige* bolusgroße Aktion.

Dieser Lauf zeigt zugleich, warum weder Trainingskennzahlen noch ein einzelner Messpunkt als Beleg genügen. Nach 46.000 Schritten meldete das Training 78,4 % Time in Range, die deterministische Auswertung dagegen 20,3 % bei praktisch konstanter Aktion (Standardabweichung 0,008). Nach 100.000 Schritten erreicht derselbe Lauf 69,5 %, jedoch nicht durch Boli, sondern durch Anheben der konstanten Rate auf das 1,29-fache der Basalrate: 41,6 gegen 30,4 Einheiten Tagesinsulin, Aktionsmittel +0,051 bei Standardabweichung 0,065. Der Agent findet die Basalratenanpassung und nie den Bolus. Dieselbe Ausweichlösung zeigen später die CGM-Agenten.

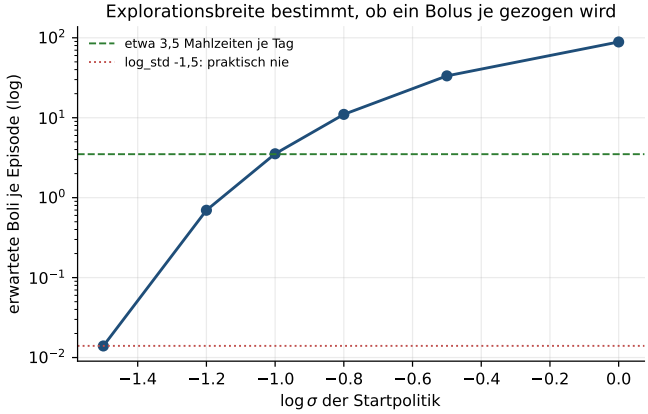



**Abbildung 2:** Erwartete Zahl bolusgroßer Aktionen je Episode über die Explorationsbreite. Der nutzbare Bereich liegt zwischen zwei Fehlerarten.

**Belohnung v1.** Mit dem Risikoindex als alleinigem Signal erreicht der Agent zunächst 92,0 % Time in Range und wird danach schlechter: der mittlere Blutzucker sinkt von 136 auf 117 mg/dL, der Anteil unterhalb des Zielbereichs steigt von 0 auf bis zu 12,70 %, weit über den Grenzwert von 4 %. Die Ursache liegt im Index selbst: er bewertet milde Unterzuckerung günstiger als mäßige Überzuckerung. Ein Blutzucker von 60 mg/dL kostet unter v1 1,36, einer von 250 mg/dL dagegen 2,24; unter v2 kehrt sich das mit 2,79 gegen 2,24 um. Der Agent maximiert korrekt die vorgegebene Belohnung; falsch war die Belohnung.

## 5.3 Imitation: die Lücke als eine Zahl, zweimal gemessen

Beide Schüler werden auf denselben Beobachtung-Aktion-Paaren desselben Lehrers trainiert, mit identischem Netz und identischem Verfahren. Der einzige Unterschied ist der Beobachtungsraum.

**Tabelle 6:** Güte der Imitation des klinischen Reglers. Die Werte ändern sich nicht, wenn statt eines Patienten zwanzig verschiedene Physiologien zugrunde liegen.

| | ein Patient | | 20 Patienten | |
|---|---|---|---|---|
| Schüler | Val-MSE | Korrelation | Val-MSE | Korrelation |
| privilegiert | 0,00008 | **0,995** | 0,00012 | **0,991** |
| nur CGM | 0,00589 | **0,091** | 0,00557 | **0,100** |

Das Ergebnis ist physiologisch zu erwarten, und darin liegt seine Aussagekraft: ein Mahlzeitenbolus muss dem Glukoseanstieg *vorausgehen*. Zum Entscheidungszeitpunkt ist im Sensorverlauf nichts davon zu sehen, und der Sensor hinkt zusätzlich um zwölf Minuten hinterher.

## 5.4 Referenzwerte auf der Kohorte

**Tabelle 7:** Referenzregler auf den zehn Held-out-Patienten, 200 Episoden je Regler.

| Regler | TIR | TBR ges. | TBR L2 | mittl. BG | Abbrüche | Ziele |
|---|---|---|---|---|---|---|
| konstante Basalrate | 36,6 % | 0,0 % | 0,00 % | 252 | 37/200 | 2/6 |
| Basal-Bolus (klinisch) | 82,4 % | 5,6 % | 1,51 % | 135 | 7/200 | 4/6 |

Zwei Punkte, die der Einzelpatientenversuch verdeckt hatte. Erstens erfüllt die klinische Referenztherapie auf der Kohorte die Konsensziele **nicht**: sie verfehlt beide Hypoglykämie-Grenzen (5,6 % gegen 4 % erlaubt, 1,51 % gegen 1 %). Getragen wird das fast vollständig von den Kindern mit 11,73 % Zeit unterhalb des Zielbereichs; die Lehrbuchfaktoren aus `Quest.csv` sind für diese Gruppe zu aggressiv. Zweitens liegt die zu schlagende Marke bei 82,4 %, nicht bei den 90,9 % eines einzelnen gut regelbaren Erwachsenen.

## 5.5 Das Hauptergebnis: Information gegen Personalisierung

**Tabelle 8:** Time in Range auf den zehn Held-out-Patienten. Für die generalistischen Regler sind diese Physiologien nie trainiert, für die personalisierten sind es neue Episoden desselben Patienten. Je Zelle 200 Episoden und zwei unabhängige Trainingsdurchläufe.

| Zelle | Durchlauf 1 | Durchlauf 2 | Mittel | Spanne |
|---|---|---|---|---|
| generalistisch, privilegiert | 71,0 % | 73,3 % | 72,1 % | 2,3 |
| generalistisch, nur CGM | 42,4 % | 37,4 % | 39,9 % | 5,0 |
| personalisiert, privilegiert | 74,8 % | 72,4 % | 73,6 % | 2,5 |
| personalisiert, nur CGM | 36,7 % | 38,3 % | 37,5 % | 1,6 |
| *Ablation, nur das Sensorfenster verändert (Abschnitt 5.6):* | | | | |
| generalistisch, nur CGM, 180 min | 37,7 % | 39,5 % | 38,6 % | 1,8 |

Daraus ergeben sich die beiden gesuchten Effekte, jeweils gemittelt über alle vier Messungen: die **Informationslücke** (privilegiert minus nur CGM) beträgt 34,2 ± 4,1 Punkte bei einer Spanne von 28,6 bis 38,1, die **Personalisierung** (je Patient minus generalistisch) −0,5 ± 4,0 bei einer Spanne von −5,7 bis +3,9.

Die beiden Achsen verhalten sich völlig unterschiedlich. Die **Informationslücke** beträgt im Mittel 34,2 Prozentpunkte und liegt in jeder einzelnen der vier Messungen zwischen 28,6 und 38,1, also nie auch nur in der Nähe von null. Der **Personalisierungsgewinn** beträgt −0,5 Punkte bei einer Streuung von 4,0 und wechselt zwischen den Durchläufen das Vorzeichen. Er ist damit von null nicht zu unterscheiden.

Bemerkenswert ist das Verhältnis zur Streuung zwischen Trainingsdurchläufen. Einzelne Zellen schwanken um bis zu 5,0 Punkte allein durch den Zufallsstartwert. Diese Streuung ist genauso groß wie der gesamte gesuchte Personalisierungseffekt. Mit nur einem Durchlauf hätte diese Arbeit je nach Startwert entweder +3,9 oder −5,7 Punkte als Befund berichtet, in beiden Fällen als scheinbar belastbare Zahl. Der zweite Durchlauf war deshalb keine Absicherung im Nachhinein, sondern Voraussetzung für eine tragfähige Aussage.

Die CGM-Agenten regeln faktisch überhaupt nicht. Ihre Abbruchrate (30 bis 39 von 200) entspricht der völligen Nichtregelung (37 von 200), ihr mittlerer Blutzucker mit 234 bis 250 ebenso (Nichtre-

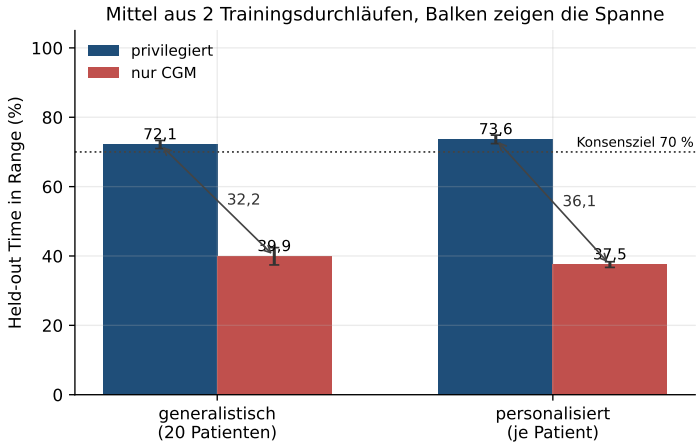



**Abbildung 3:** Mittel aus zwei Trainingsdurchläufen, die Balken zeigen deren Spanne. Der Abstand zwischen den Säulen einer Gruppe ist die Informationslücke.

gelung: 252). Sie fallen auf die Basalrate zurück, und weder Personalisierung noch Feinabstimmung ändert daran etwas.

Nach Patientengruppe, gemittelt über beide Durchläufe, erreichen die privilegierten Regler 75,8 % bei Jugendlichen, 70,4 % bei Erwachsenen und 72,6 % bei Kindern, die CGM-Regler 37,0, 35,7 und 42,3 %. Die klinische Referenz liegt bei 88,1, 90,3 und 72,3 %: sie fällt bei Kindern auf das Niveau der privilegierten Regler, weil sie dort zu aggressiv dosiert.

## 5.6 Ablation: schließt ein längeres Sensorfenster die Lücke?

Die naheliegende Kritik am bisherigen Ergebnis lautet, der CGM-Agent habe mit 36 min Sensorverlauf schlicht zu wenig gesehen. Diese Frage lässt sich messen. Verändert wurde ausschließlich die Fensterlänge, von 12 auf 60 Schritte, also auf 180 min. Insulinhistorie, Ankündigungsfenster, Netz, Schrittbudget und Startwerte bleiben gleich; der privilegierte Beobachtungsraum bleibt unberührt und dient unverändert als Vergleich. Die Beobachtungsdimension des CGM-Agenten wächst dabei von 26 auf 74.

Die Messwerte stehen in Tabelle 8. Das längere Fenster ändert die Regelgüte um −1,3 Punkte und liegt damit innerhalb der Startwertstreuung, denn allein die 36 min-Zelle schwankt um 5,0 Punkte. Die Informationslücke beträgt generalistisch 32,2 Punkte bei 36 min und 33,6 bei 180 min. Schon die Imitation zeigt dasselbe, und zwar schärfer: auf identischen Lehrerdaten bleibt der Validierungsfehler mit 0,005.572 auf sechs Nachkommastellen unverändert, die Korrelation steigt von 0,099.5 auf 0,103.0.

Ein längeres Fenster bringt bei gleicher Netzkapazität und gleichem Budget also keinen messbaren Gewinn. Nicht zulässig wäre der Umkehrschluss, längere Fenster seien schlechter: −1,3 Punkte sind von null nicht zu unterscheiden.

## 5.7 Einordnung gegenüber der klinischen Referenz

Auf der vollen Kohorte schlägt **keiner** der gelernten Regler die klinische Standardtherapie: 73,6 % im besten Fall gegenüber 82,4 %. Ein Vorversuch auf `adult#001` hatte das Gegenteil ergeben (94,5 % gegen 90,9 %); dieser Vorsprung war eine Eigenschaft dieses gut regelbaren Patienten, nicht des Verfahrens, und wird hier ausdrücklich zurückgenommen.

Eindeutig ist der Vergleich allerdings nicht. Die klinische Therapie erreicht ihre höhere Time in Range um den Preis von 5,6 % Zeit unterhalb des Zielbereichs und verfehlt damit die Sicherheitsziele, bei Kindern mit 11,73 % deutlich. Die privilegierten RL-Regler bleiben mit 0,4 % bis 2,3 % darunter. Die klinische Therapie hat die bessere Regelgüte, die gelernten Regler das geringere Unterzuckerungsrisiko.

Das heißt allerdings nicht, dass die gelernten Regler die Konsensgrenzen durchgängig einhalten: der personalisierte privilegierte Regler des zweiten Durchlaufs liegt mit 1,71 % Zeit unterhalb 54 mg/dL über dem Ziel von 1 %. Sie sind sicherer als die Referenz, nicht sicher im Sinne des Konsens.

Von dieser Korrektur unberührt bleibt die eigentliche Fragestellung. Die Informationslücke wird durch die Kohorte nicht kleiner, sondern besser belegt: statt 55,9 Punkten an einem Patienten nun 34,2 ± 4,1 Punkte über zehn Patienten, zwei Trainingsdurchläufe und beide Personalisierungsstufen.

# 6 Sensitivitätsanalyse der Patientenparameter

Die bisherigen Ergebnisse gelten für einen Patienten. Die Frage, welche physiologischen Größen überhaupt darüber entscheiden, wie gut sich ein Patient regeln lässt, wird mit einem Morris-Screening beantwortet (Morris 1991), umgesetzt mit SALib (Herman und Usher 2017).

## 6.1 Vorgehen

Zehn physiologisch interpretierbare Parameter des Modells werden um ±20 % um ihren Nominalwert variiert. Der Stichprobenplan umfasst zwölf Trajektorien, also 132 Parametersätze, jeder ausgewertet über zwei Mahlzeitenszenarien. Als Zielgröße dient die Time in Range unter der klinischen Referenztherapie. Berichtet werden der mittlere absolute elementare Effekt $\mu^*$ und dessen Streuung $\sigma$.

## 6.2 Ergebnis

**Tabelle 9:** Morris-Screening. $\mu^*$ in Prozentpunkten Time in Range.

| Parameter | $\mu^*$ | $\sigma$ | Bedeutung |
|---|---|---|---|
| kp1 | **33,02** | 34,43 | Basisrate der endogenen Glukoseproduktion |
| kp3 | 16,30 | 17,91 | Insulinwirkung auf die Glukoseproduktion |
| Km0 | 14,00 | 14,99 | Michaelis-Konstante der Glukoseaufnahme |
| Vmx | 9,56 | 9,55 | insulinabhängige Glukoseaufnahme |
| kmax | 7,01 | 3,51 | maximale Magenentleerungsrate |
| kd | 2,07 | 1,94 | Dissoziation des subkutanen Insulins |
| ka1 | 0,78 | 0,80 | Resorption des subkutanen Insulins |
| kabs | 0,60 | 0,60 | Resorptionsrate aus dem Darm |
| ksc | 0,59 | 0,47 | Diffusion Plasma zu subkutaner Glukose |
| u2ss | **0,00** | 0,00 | stationärer Insulinbedarf |

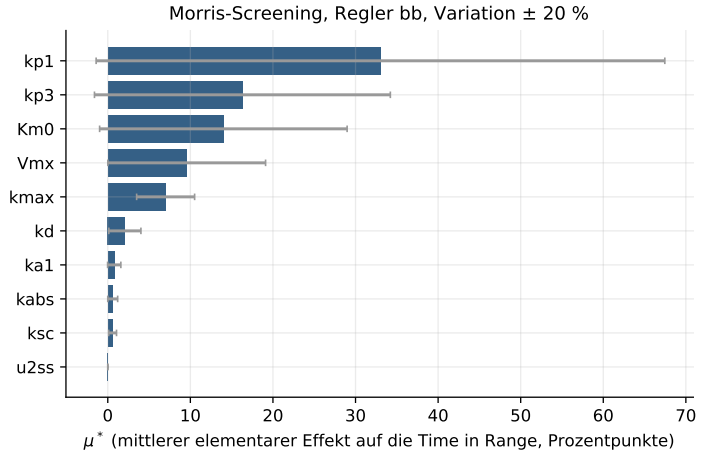



**Abbildung 4:** Elementare Effekte der Patientenparameter auf die Time in Range.

## 6.3 Einordnung

Drei Beobachtungen sind bemerkenswert.

**Die physiologische Streuung dominiert die Reglerwahl.** Über alle Parametersätze schwankt die Time in Range zwischen 47,0 % und 96,1 % bei einem Median von 75,4 %, und zwar bei *unverändertem* Regler. Der Abstand zwischen dem am besten und dem am schlechtesten regelbaren Parametersatz ist damit größer als der Zugewinn, den ein besserer Regler auf einem festen Patienten erzielt.

**Die endogene Glukoseproduktion ist der kritische Parameter.** Mit $\mu^* = 33{,}02$ wirkt kp1 doppelt so stark wie der nächstwichtige Parameter. Genau diese Größe kennt ein Regler nicht und kann sie auch nicht messen. Das hohe $\sigma$ zeigt zudem starke Wechselwirkung mit den übrigen Parametern.

**Der Nulleffekt von u2ss bestätigt das Verfahren.** Dass ausgerechnet der stationäre Insulinbedarf die Zielgröße gar nicht verändert, ist kein Fehler: die Referenztherapie leitet ihre eigene Basalrate aus

u2ss ab. Modell und Regler verschieben sich gemeinsam, der Effekt hebt sich exakt auf. Der Befund entspricht dem Parameter $E_{An}$ im Vorlesungsbeispiel am Noble-Modell, der die dortige Zielgröße ebenfalls nicht beeinflusst, und zeigt, dass das Screening Scheineffekte zuverlässig aussortiert.

Bemerkenswert ist schließlich, dass ksc, also genau die Diffusionskonstante der Sensorverzögerung aus Gleichung (1), mit $\mu^* = 0{,}59$ kaum wirkt. Die in Abschnitt 5 gemessene Lücke entsteht demnach nicht in erster Linie durch die Trägheit des Sensors, sondern durch die fehlende Mahlzeiteninformation.

# 7 Diskussion

## 7.1 Information entscheidet, Personalisierung nicht

Der Vergleich der beiden Achsen ist das eigentliche Ergebnis und beantwortet zugleich F1 und F5. Die Informationslücke beträgt $34{,}2 \pm 4{,}1$ Punkte und liegt in allen vier Messungen zwischen 28,6 und 38,1. Der Personalisierungsgewinn beträgt $-0{,}5 \pm 4{,}0$ und wechselt zwischen den Durchläufen das Vorzeichen. Ein eigener Regler je Patient bringt in diesem Aufbau also nichts, was sich von Rauschen unterscheiden ließe.

Das ist eine schärfere Aussage als ein bloßer Größenvergleich. Nicht „die eine Achse wiegt schwerer als die andere“, sondern: die eine Achse entscheidet über Erfolg oder Misserfolg, die andere ist messtechnisch wirkungslos.

Die Streuung zwischen Trainingsdurchläufen erreicht in einzelnen Zellen 5,0 Punkte und ist damit genauso groß wie der gesamte gesuchte Personalisierungseffekt. Ein einzelner Durchlauf hätte je nach Zufallsstartwert $+3{,}9$ oder $-5{,}7$ Punkte ergeben. Beide Zahlen hätten für sich genommen überzeugend ausgesehen.

Zu F2 und F3 fallen die Antworten knapper aus. Reinforcement Learning allein genügt nicht: ohne Warmstart scheitert das Verfahren an einem Zielkonflikt, den die Explorationsbreite nicht auflöst, weil eng genug für den Patienten zu eng für jeden Bolus ist (0,014 Treffer je Episode) und weit genug für Boli 97 % Abbrüche bedeutet. Über den Erfolg entscheiden drei Entwurfsentscheidungen, die sich alle vorab oder durch Messung begründen ließen: der logarithmische Aktionsraum, weil die klinische Referenzverteilung um den Faktor 124 schief ist; die Abbruchstrafe als verbleibende Episodendauer mal maximales Risiko, weil eine flache Strafe rechnerisch zum absichtlichen Beenden einlädt; und die asymmetrische Hypoglykämiestrafe, nachdem der Risikoindex die klinische Rangfolge nachweislich verfehlte. F4 beantwortet Abschnitt 6.

## 7.2 Was das Ergebnis bedeutet und was nicht

Die naheliegende Fehlinterpretation wäre, den CGM-Agenten für zu schwach trainiert zu halten. Dagegen sprechen vier Messungen: seine Regelgüte bewegt sich über 600.000 Trainingsschritte nicht aus einem schmalen Band heraus; sie ändert sich nicht durch Personalisierung; reine Imitation eines nachweislich guten Lehrers bringt ihn ebenfalls nicht weiter; und seine Abbruchrate entspricht der völligen Nichtregelung. Die Ursache ist zudem physiologisch benennbar.

Die Sensitivitätsanalyse schärft die Deutung. Die Diffusionskonstante der Sensorverzögerung wirkt mit $\mu^* = 0{,}59$ kaum auf die Zielgröße. Nicht die Trägheit des Sensors ist das Hauptproblem, sondern die fehlende Ankündigung. Das deckt sich mit der klinischen Praxis, in der vergessene oder falsch geschätzte Mahlzeitenboli eine der häufigsten Ursachen für Entgleisungen sind.

Für die Bewertung von Simulationsstudien folgt eine allgemeinere Warnung: wer einen Regler in einer Umgebung trainiert, die den wahren Zustand vorhält, misst möglicherweise die Güte der Information und nicht die des Verfahrens.

Für eine Arbeit über den Einfluss verfügbarer Information passt der Nebenbefund aus Abschnitt 5.6 und der Kohortenauswertung: auch die Aussagekraft eines Vergleichs hängt daran, wie breit seine Grundlage gewählt wurde. Ein gut regelbarer Erwachsener lässt jeden Regler besser aussehen.

## 7.3 Ein Fehler in der Seed-Vergabe und was er kostete

Ein Fehler verdient eine eigene Notiz, weil er die Personalisierungsachse zunächst vollständig verfälscht hatte. Jeder Arbeitsprozess der vektorisierten Umgebung erhielt einen Seed-Block fester Größe, nämlich `seed_base` $+ i \cdot 10000$. Bei 24 Prozessen reichten die Trainings-Seeds damit bis 239.999, während der Auswertungsbereich bei 100.000 beginnt. Die personalisierten Regler trainierten dadurch

auf 19 der 20 Episoden, auf denen sie anschließend gemessen wurden, und zwar auf demselben Patienten. Der so gemessene Personalisierungsgewinn von +5,4 Punkten verschwand nach der Korrektur vollständig ($-0{,}5 \pm 4{,}0$). Der generalistische Regler war nur schwach betroffen, weil die Seeds zwar überlappten, die Patienten jedoch nicht.

Die Blockgröße füllt nun genau das Intervall $[0, \text{HELDOUT_SEED_BASE})$, abgesichert durch eine Zusicherung im Code. Alle 22 betroffenen Trainingsläufe wurden verworfen und wiederholt. Die Lehre daraus ist allgemein: eine Trennung von Trainings- und Auswertungsdaten ist erst dann belegt, wenn sie erzwungen und nicht nur beabsichtigt ist.

### 7.4 Grenzen der Arbeit

**Zwei Zufallsstartwerte.** Je Zelle liegen zwei unabhängige Trainingsdurchläufe vor. Das genügt, um die Größenordnung der Streuung zu zeigen und den Personalisierungseffekt als nicht signifikant auszuweisen, nicht aber für eine belastbare Verteilungsaussage. Fünf Durchläufe je Zelle wären der nächste Schritt.

**Entwurfsraum des CGM-Agenten.** Die Fensterlänge ist geprüft: 180 min statt 36 min ändern die Regelgüte um $-1{,}3$ Punkte (Abschnitt 5.6). Ungeprüft bleiben ein rekurrentes Netz, eine größere Netzkapazität und eine Mahlzeitenerkennung aus dem Anstieg. Die Lücke besteht unter den untersuchten Bedingungen, unschließbar ist sie damit nicht.

**Ungleiches Rechenbudget.** Der generalistische Regler erhielt 600.000 Schritte für zwanzig Patienten, die personalisierten je 250.000 für einen, pro Patient also mehr. Da der Personalisierungseffekt klein ausfällt, würde ein Angleichen die Aussage eher stärken.

**Simulation bleibt Simulation.** Das UVA/Padova-Modell ist von der FDA als Ersatz für präklinische Tests anerkannt, bildet aber weder Sport noch Krankheit, Stress oder Insulinresistenzschwankungen ab. Dass der Vergleich asymmetrisch angelegt ist, ist dagegen kein Mangel, sondern sein Zweck: der Abstand zwischen beiden Agenten ist die gesuchte Größe.

## 8 Fazit und Ausblick

Die Arbeit kreuzt zwei Achsen auf dem UVA/Padova-Modell: was der Regler *sieht* und auf wen er *zugeschnitten* ist. Bewertet wird nach den Konsenszielen zur Time in Range auf zehn Held-out-Patienten.

1. **Was der Regler sehen kann, entscheidet über Erfolg oder Misserfolg** ($34{,}2 \pm 4{,}1$ Punkte, in keiner Messung nahe null), **Personalisierung dagegen nicht messbar** ($-0{,}5 \pm 4{,}0$, wechselndes Vorzeichen). Ein einzelner Durchlauf hätte getäuscht: die Streuung zwischen Startwerten erreicht 5,0 Punkte und damit die Größe des gesuchten Effekts.

2. **Die Lücke ist kein Budget- und kein Fensterproblem.** Sie zeigt sich schon in der Imitationsgüte (Korrelation 0,991 gegen 0,100), bleibt über 600.000 PPO-Schritte bestehen und überlebt ein fünffach längeres Sensorfenster ($-1{,}3$ Punkte). Die Ursache ist benennbar: ein Bolus muss dem Glukoseanstieg vorausgehen, im Sensorverlauf ist davon noch nichts zu sehen. Nicht die Sensorträgheit ist der Engpass, denn deren Diffusionskonstante wirkt mit $\mu^* = 0{,}59$ kaum, die endogene Glukoseproduktion dagegen mit $\mu^* = 33{,}02$.

3. **Entwürfe müssen durchgerechnet werden.** Eine flache Abbruchstrafe machte das Beenden der Episode rechnerisch attraktiv, und der Risikoindex allein trieb den Agenten in 12,70 % Zeit unterhalb des Zielbereichs.

4. **Die Breite der Grundlage entscheidet über die Aussage.** Auf einem einzelnen gut regelbaren Erwachsenen übertraf der privilegierte Agent die klinische Referenz, auf der Kohorte nicht mehr (73,6 % gegen 82,4 %). Umgekehrt verfehlt die Referenz dort die Sicherheitsziele, bei Kindern mit 11,73 % Zeit unterhalb des Zielbereichs.

### 8.1 Ausblick

Die Fensterlänge ist als Erklärung ausgeschieden. Offen bleibt, wie viel der Lücke ein rekurrentes Netz oder eine Mahlzeitenerkennung aus dem Anstieg zurückgewinnt. Statistisch wären fünf Zufallsstartwerte je Zelle der nächste Schritt. Klinisch verdient der pädiatrische Befund eine eigene Untersuchung: 11,73 % Zeit in der Unterzuckerung unter Lehrbuchfaktoren.

Übertragbar ist der Aufbau selbst. Der Vergleich zweier Agenten, die sich ausschließlich im Beobachtungsraum unterscheiden, passt auf jedes Simulationsmodell der Life Sciences, in dem ein Verfahren später mit weniger Information auskommen muss als der Simulator bereitstellt.

## Literaturverzeichnis


Battelino, T., T. Danne, R. M. Bergenstal, S. A. Amiel, R. Beck, T. Biester, E. Bosi, B. A. Buckingham, W. T. Cefalu, K. L. Close u. a. (2019). „Clinical Targets for Continuous Glucose Monitoring Data Interpretation: Recommendations From the International Consensus on Time in Range“. In: *Diabetes Care* 42.8, S. 1593–1603. DOI: 10.2337/dci19-0028.

Chen, D., B. Zhou, V. Koltun und P. Krähenbühl (2019). „Learning by Cheating“. In: *Conference on Robot Learning (CoRL)*.

Dalla Man, C., F. Micheletto, D. Lv, M. Breton, B. Kovatchev und C. Cobelli (2014). „The UVA/PADOVA Type 1 Diabetes Simulator: New Features“. In: *Journal of Diabetes Science and Technology* 8.1, S. 26–34. DOI: 10.1177/1932296813514502.

Herman, J. und W. Usher (2017). „SALib: An Open-Source Python Library for Sensitivity Analysis“. In: *Journal of Open Source Software* 2.9, S. 97. DOI: 10.21105/joss.00097.

Kovatchev, B. P., D. J. Cox, L. A. Gonder-Frederick und W. Clarke (1997). „Symmetrization of the Blood Glucose Measurement Scale and Its Applications“. In: *Diabetes Care* 20.11, S. 1655–1658. DOI: 10.2337/diacare.20.11.1655.

Morris, M. D. (1991). „Factorial Sampling Plans for Preliminary Computational Experiments“. In: *Technometrics* 33.2, S. 161–174. DOI: 10.1080/00401706.1991.10484804.

Raffin, A., A. Hill, A. Gleave, A. Kanervisto, M. Ernestus und N. Dormann (2021). „Stable-Baselines3: Reliable Reinforcement Learning Implementations“. In: *Journal of Machine Learning Research* 22.268, S. 1–8.

Ross, S., G. J. Gordon und J. A. Bagnell (2011). „A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning“. In: *Proceedings of the 14th International Conference on Artificial Intelligence and Statistics (AISTATS)*, S. 627–635.

Schulman, J., F. Wolski, P. Dhariwal, A. Radford und O. Klimov (2017). „Proximal Policy Optimization Algorithms“. In: *arXiv preprint arXiv:1707.06347*.

Sutton, R. S. und A. G. Barto (2018). *Reinforcement Learning: An Introduction*. 2. Aufl. Cambridge, MA: MIT Press.

Virtanen, P., R. Gommers, T. E. Oliphant u. a. (2020). „SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python“. In: *Nature Methods* 17, S. 261–272. DOI: 10.1038/s41592-019-0686-2.

Xie, J. (2018). *simglucose v0.2.11: A Type-1 Diabetes Simulator Implemented in Python for Reinforcement Learning Purpose*. https://github.com/jxx123/simglucose. abgerufen am 07.08.2026.